MACHINE LEARNING CANVAS

Designed for: MiBici | Designed by: Equipo 43 | Date: 18-oct-2026 | Iteration: 2

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

P1 · Regresión. Entidad: estación. Viajes iniciados por hora, para las 24 h del día siguiente.

P2 · Clasificación (3 clases). Entidad: estación y ventana de 2 h. ¿Se vacía, se llena o no hay riesgo en cada ventana del día siguiente? Riesgo aproximado con un inventario simulado a partir de los viajes y la capacidad.

P3 · Clustering. Entidad: estación. Grupos por perfil de uso.

Observados: P1 y P2 al cerrar el día o ventana (con los viajes); P3 no tiene resultado observable.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1: el operador define cuántas bicicletas y cuánto personal asignar por zona y turno.

P2: el equipo de rebalanceo prioriza qué estaciones visitar con una lista diaria ordenada por probabilidad de riesgo.

P3: planeación urbana decide dónde expandir y qué estrategia aplicar a cada tipo de estación.

Opcional: dejar estaciones sin intervenir para medir el efecto del rebalanceo.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiarios: operador del sistema (P1 y P2) y planeación urbana (P3).

Problema: la flota y el rebalanceo se reparten con reglas fijas o por intuición. Hay estaciones vacías (el usuario no encuentra bicicleta), llenas (no puede devolverla) y camiones que van a donde no hacía falta.

Valor: anticipar demanda y desequilibrios para mover bicicletas antes de que falten, reducir recorridos innecesarios y respaldar la expansión con evidencia.

Integración: corrida diaria por lotes que se consulta antes de cada turno: pronóstico por zona y turno (P1), ranking de estaciones en riesgo (P2) y mapa de grupos (P3), en un tablero o CSV. No requiere tiempo real ni cambiar la operación actual.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Descarga automatizada desde el portal de datos abiertos con un comando en dataset.py, sin pasos manuales.

Sin etiquetado manual: las variables objetivo se derivan de los propios viajes.

Se normalizan columnas, codificación y fechas, y se guarda en Parquet con manifiesto (registros y hash) versionado en Git.

Se agrega cada mes nuevo publicado. Costo nulo.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Portal de datos abiertos de MiBici:

- **Viajes:** datos_abiertos_AAAA_MM.csv (id de viaje, usuario, fecha y hora de inicio y fin, estación de origen y destino).
- **Estaciones:** nomenclatura_2026_09.csv (id, nombre, latitud, longitud y capacidad).
- **Opcional:** calendario de feriados de México.

No incluyen inventario de bicicletas por estación; por eso P2 usa una aproximación.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costos: en P2, un faltante no anticipado deja al usuario sin servicio; una falsa alarma manda un camión sin necesidad. Se prioriza el recall de la clase en riesgo por considerar que es peor dejar sin servicio a usuarios que gastar recursos por falsos positivos. En P1, subestimar deja zonas sin bicicletas y sobrestimar inmoviliza flota. Los montos los define el operador.

Simulación: backtesting con los meses más recientes (partición temporal, sin usar datos del futuro), comparando el modelo contra su baseline en las mismas horas.

Despliegue: superar al baseline en prueba (P1: menor MAE y RMSE; P2: mayor PR-AUC y recall; P3: mayor silhouette y grupos interpretables en el mapa).

Equidad: revisar que el error no sea peor en zonas de bajo uso; no usar género, edad ni id de usuario.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Por lotes, no en tiempo real. P1 y P2: una corrida diaria que genera el día siguiente (P2 en ventanas de 2 h). P3: recálculo mensual o trimestral.

Tiempo disponible: horas; la corrida es nocturna y usa solo datos hasta el cierre del día anterior.

Cómputo: una laptop o un servidor pequeño; modelos tabulares ligeros de scikit-learn.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

P1: baseline = misma hora de la semana pasada; candidato = gradient boosting.

P2: baselines = clase mayoritaria y frecuencia; candidatos = regresión logística y gradient boosting con pesos de clase.

P3: baseline = K-means; candidato = K-means

Reentrenar cada mes o si se detecta deriva. Cada run se registra en MLflow.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Temporales: hora, día de la semana, mes, feriado.

De estación: capacidad, latitud, longitud.

Historial (solo pasado): rezagos de 1, 24 y 168 h, promedios móviles y balance neto reciente (llegadas – salidas).

P2: frecuencia de cada clase en las 4 semanas anteriores (misma estación, día y ventana) y balance neto acumulado como fracción de la capacidad.

P3: perfil horario normalizado (día hábil y fin de semana), volumen total y razón salidas/llegadas.

Los viajes se agregan a conteos por estación-hora. No se usan datos personales del usuario.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

P1: MAE y RMSE diarios contra los viajes reales; alerta si el error empeora frente al baseline.

P2: PR-AUC, recall y precisión semanales; negocio: horas-estación en riesgo tras el rebalanceo.

P3: estabilidad de los grupos (silhouette y cambios de asignación) en cada recálculo.

Deriva: cambios por temporada o eventos en la distribución de la demanda.

Revisión: mensual, junto con el reentrenamiento.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."
— Daitan, now part of Coforge, a global IT services firm

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```